中文数学大模型后训练算法与可信评估

技术报告：一条 LoRA-SFT + DPO 链路，以及一次「指标上升、能力退化」的归因

代码：`math-posttraining-project-v2` · 数据 seed 20251109 · 指标源：`reports/results.jsonl`（245 条记录，9 条为 Qwen 权重层待运行）

摘要. 本项目构建一条中文数学后训练链路，包含参数化题目生成、严格三态验证器、 LoRA-SFT、三组对照偏好数据、DPO 与四个泛化子集上的生成评测。起点是一次失败复现： 旧项目训练损失与 reward margin 单调下降或上升，自由生成的符号准确率却由 62.5% 退回 50%。 审计把原因定位到三处测量失效：40 条测试集实际只含 2 道独立题，旧评测器判对的 65 条中 32 条是假阳性，240 条偏好对里没有一条含真实数学错误。为了在没有 GPU 的机器上验证 目标函数层面的机制，构建了 7 维可解析梯度的 log-linear 策略实验台，SFT 与 DPO 均为 真实训练，解析梯度经中心有限差分校验（最大误差 3.44e-11）。三组偏好对照的 reward accuracy 同为 1.0000，长度偏置劫持率分别为 0.7241、0.1864、0.0720， 参考模型锚错使 KL 由 0.0513 升至 0.5179。三个测量问题各自给出估计量与区间： 表面特征 AUC 从 1.0000 降到 0.5000，设计效应 15 对应有效样本量 2.6667， 验证器 FPR 0.5000 使观测准确率 0.7425 被校正为 0.6496。Qwen3-0.6B 的权重训练尚未运行， 9 个模型指标保持 pending，不在本报告中给出数值。

1 问题与起点

旧项目报告了两组互相矛盾的证据。一方面，teacher-forced loss 从 4.41 降到 2.50， reward margin 随 beta 单调上升；另一方面，同一套权重在自由生成下的符号准确率是 Base 50%、SFT 62.5%、DPO 50%，DPO 把 SFT 的增益退回了起点。更直接的矛盾是， 三份报告对同一个模型给出三个不同的 perplexity 数值，极差 42.0887， 而仓库里保存的 adapter 无法复现其中任何一组最好看的数字。

把现象拆成三个可检验的假设，比笼统地说「调参失败」更有用：

- **H1 数据不承载质量信号。**偏好对的标签可以由长度与格式线索完全预测， 梯度方向与真实数学质量无关。
- **H2 评测器有系统性误判。**子串包含式的判对把推导里出现的数字当成答案， 观测准确率高于真实准确率。
- **H3 推断单位错误。**测试集里的 40 条是 2 道题的伪重复， 把簇内完全相关的样本当独立样本会把方差低估一个数量级。

表 1 是对 H1 至 H3 的直接复算。每一项都由 `src/research/legacy_audit.py` 与 `cluster_inference.py` 在旧项目原始文件上重新计算，不引用旧报告里的任何数字。

表 1　旧项目审计结果（在原文件上复算）

检查项	结果	含义
测试集条数 / 去编号后唯一题干	40 / 2	有效样本量是 2，不是 40
伪重复倍数	20	同题重复 20 次
旧判对条数 / 严格重判仍对 / 假阳性	65 / 33 / 32	假阳性率 0.4923
标为「错误答案」的偏好对 / 真错	80 / 0	错误答案生成器对训练集答案全部无效
exact 与 symbolic 逐条相同的比例	1.0000	SymPy 分支从未生效
同一模型 PPL 的不同取值个数 / 极差	3 / 42.0887	报告之间不可互证

严格验证器在旧项目 120 条生成输出上判 33 条 correct、87 条 unverifiable，后者主要来自 64 token 截断与不受支持的 LaTeX 写法。

2　后训练链路

2.1　数据构造与切分

题目由 12 个参数化题型族生成，每题参数唯一，答案先由题型族自带的 oracle 计算， 再用第二条独立计算路径交叉验证，不一致直接抛错。切分以题型族与参数签名为单位， 而不是以字符串为单位，这样「同题改写」不会跨 split 泄漏。测试集额外拆成四个子集： 未见参数、同义改写、反事实（改动条件后重算答案）、未见题型族。

表 2　数据规模与切分检查

项	值	项	值
题目总数	600	唯一题干数	600
题型族	12	唯一参数签名	600
跨 split 参数重叠	0	oracle 与验证器一致	600 / 600
测试集条数	303	测试集族数	12

2.2　三态评测器

答案比较不使用子串包含。做法是把候选答案与标准答案都解析成受限语法的表达式 （支持整数、分数、小数、逗号分隔的多解、单变量多项式），在有理数域上做精确相等， 必要时对多项式做规范形比较。解析失败抛 `ParseError`，由上层记为 `unverifiable`，不回退到字符串匹配。判定因此是三态： `correct`、`incorrect`、`unverifiable`。 第三态单独统计，不折进错误率。

这个选择的代价是覆盖率。旧项目 120 条生成输出里有 87 条不可核验， 主要因为解码在 64 token 处截断，答案标记没写完。新协议把 `max_new_tokens` 固定为 256，并把这个比例作为独立指标报告， 而不是把它当成「答错」来压低准确率。

2.3 SFT 的 assistant-only loss

对话样本由 prompt 与 assistant completion 拼接。旧实现对整段序列计算 NLL， 模型只需记住重复出现的题干就能把 loss 压低，指标与数学能力脱钩。 修正版用 chat template 分别渲染完整对话与只到 prompt 的文本，断言前者以后者为前缀， 再用 fast tokenizer 的 `offset_mapping` 在字符级定位边界， 把起点小于 prompt 长度的 token 的 label 置为 -100。总 NLL 按 completion token 加权， 训练与验证共用同一 mask。

2.4 三组对照偏好数据

三组数据回答同一个问题：DPO 的梯度到底花在哪个特征上。shortcut 组复刻旧项目的缺陷， rejected 更短、答案其实正确。deconfounded 组把长度与格式严格对齐，只改数学内容， rejected 是把推导里所有答案出现处等长替换为错误值，长度差恒为 0、格式标记一致。 length_reversed 组故意反转长度线索，rejected 更长但答案错误。

表 3　三组偏好数据的构造检查

组	对数	真错误率	平均长度差	格式匹配率
shortcut	756	0.0000	27.7	0.3333
deconfounded	249	1.0000	0.0	1.0000
length_reversed	249	1.0000	22.0	1.0000

平均长度差取绝对值，shortcut 组 chosen 更长，length_reversed 组 rejected 更长。

2.5 DPO 与参考模型

DPO 的参考策略必须是 SFT 模型。TRL 在 `ref_model=None` 且策略是 `PeftModel` 时会 disable adapter，KL 锚点于是落在未训练的 base 上， SFT adapter 的参数被当作可直接优化的变量，目标函数不再是原始 DPO。 修正版用独立基座实例加载冻结的 SFT adapter 显式传入，训练前逐参数断言 ref 与 policy 初始一致，并把真正使用的 ref 快照落盘。

$$L(\theta) = -(1/n)\,\Sigma_i \log \sigma(\,\beta\,[\,\log(\pi_\theta(y_i^+|x_i)\,/\,\pi_{\text{ref}}(y_i^+|x_i)) - \log(\pi_\theta(y_i^-|x_i)\,/\,\pi_{\text{ref}}(y_i^-|x_i))\,]) \tag{1}$$

beta 不能只看 reward margin。固定策略时 margin 等于 beta 乘 log-ratio 差， 随 beta 线性增长是恒等式。可报告的量是策略相对参考模型的 KL，以及下游生成准确率。 真实模型里配分函数不可算，KL 用从策略采样的 $\log \pi_\theta - \log \pi_{\text{ref}}$ 均值估计，按 prompt 聚类给 bootstrap 区间。

3　算法机制实验台

3.1　为什么单独做一层

没有 GPU 时，权重层的 SFT 与 DPO 无法执行，但目标函数层面的性质仍然可以验证， 前提是配分函数可算。把策略限制为候选集上的 log-linear 模型， $\log \pi_\theta(y|x) = \theta\cdot\varphi(x,y) - \log Z_\theta(x)$， 其中 $Z_\theta(x) = \Sigma_{y\in Y(x)} \exp(\theta\cdot\varphi(x,y))$。 同一 prompt 下 Z 在成对比较里抵消，DPO 的隐式 reward 差、梯度和 KL 都有闭式解。 这一层不替代权重训练，它回答的是「目标函数是否真的在奖励长度」。 算法层、权重层 pilot 与完整协议三层在报告中始终分开标注。

3.2　模型与梯度

特征 φ 取 7 维：字符长度、是否含最终答案标记、LaTeX 标记数、数字个数、标点数、换行数， 以及由严格验证器给出的正确性指示。前 6 维是表面特征，最后一维是质量的可观测代理。 令 $\Delta_i = (\theta - \theta_{ref})\cdot(\varphi_i^+ - \varphi_i^-)$， 式 (1) 化为

$$L = -(1/n)\,\Sigma_i \log \sigma(\beta\Delta_i), \qquad \nabla_\theta L = -(\beta/n)\,\Sigma_i (1-\sigma(\beta\Delta_i))\,(\varphi_i^+ - \varphi_i^-) \tag{2}$$

式 (2) 是实验台里实际执行的更新，也是有限差分校验的对象。SFT 阶段在 chosen 上做 最大似然，梯度为 $E_{\pi_\theta}[\varphi] - \varphi(y^+)$， 得到 θ_{sft} 作为 DPO 的策略初值与参考模型。

3.3　设置

SFT 用 252 条指令、120 步、学习率 0.03。 DPO 每组 400 步、学习率 0.08、beta 0.1。下游用 2×2 平衡探针： 正确/错误 × 短/长，短对与短错等长，长对与长错等长，另设一组对抗探针， 让「短的正确」与「明显更长的错误」二选一。所有分数用 softmax 概率加权， 不用硬 argmax，避免平局时按索引取值造成虚高。

3.4　结果

表 4　三组偏好数据训练后的策略行为（beta 0.1，120 道探针； reward acc 为 reward accuracy，劫持率为对抗探针中选中「更长但错误」回答的概率）

组	reward acc	margin	劫持率	θ_quality	θ_length	KL
shortcut	1.0000	0.1696	0.7241	2.0335	0.5651	0.0847
deconfounded	1.0000	0.1165	0.1864	2.8226	0.2470	0.0513
length_reversed	1.0000	0.1321	0.0720	2.8178	-0.0082	0.0534

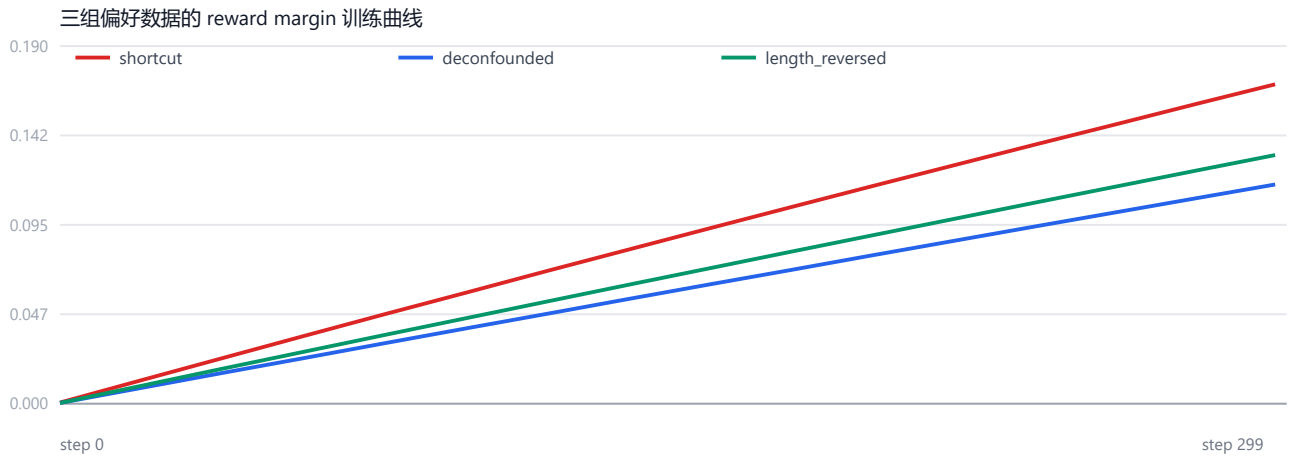


图 1　三组偏好数据的 reward margin 均随训练上升，训练损失无法区分它们。 数据来自 reports/algo_lab_curves.json。

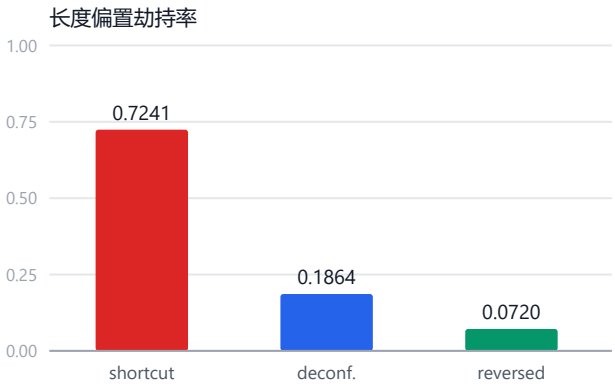


图 2　对抗探针里选「更长但错误」的概率。

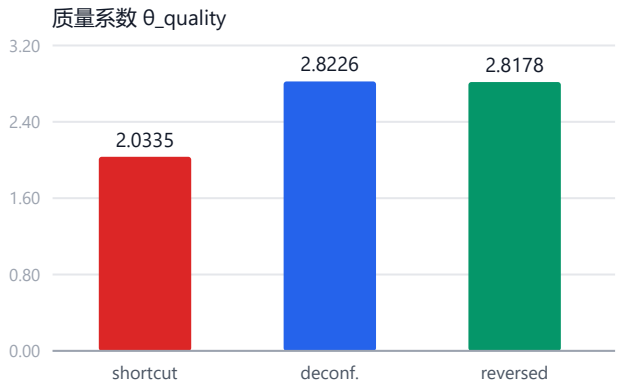


图 3　DPO 在正确性特征上累积的权重。

三组的 reward accuracy 完全一致，reward margin 也都上升，训练日志看不出差别。 分歧出现在把长度与正确性拆开之后：shortcut 组把更多梯度放在长度特征上， 质量系数只有 2.0335，对抗探针里 72.4% 的回答是更长但错误的那个； 去混淆组的质量系数升到 2.8226， 劫持率降到 18.6%。 length_reversed 组的长度系数为负（-0.0082）， 说明长度线索的方向被成功反转，而质量方向仍然被学到。

主探针的准确率同样分化：shortcut 组 0.8843， 去混淆组 0.9439。差距不大，是因为主探针里 正确与错误的长度差被刻意做得温和；一旦把长度差拉大，差距就出现在劫持率上。 这也是为什么单看一个总体准确率不足以判断 DPO 学到了什么。

3.5　参考模型锚点与 beta

表 5　参考模型锚点错误与 beta 扫描

设定	KL	下游准确率	说明
ref = SFT（正确）	0.0513	0.9439	标准 DPO 推导
ref = base，policy 从 SFT 出发	0.5179	0.9439	TRL 在 ref_model=None 时的实际行为
锚点造成的 KL 差	0.4666	—	KL 被放大约 10.1 倍

锚错不会改变 reward accuracy，因为它只依赖成对差，但仍然会通过 KL 改变正则强度， 并让「偏离参考模型多少」这个诊断量失去意义。表 5 是旧项目 `ref_model=None` 的直接量化后果。

表 6　beta 扫描（deconfounded 组，固定其余超参）

beta	reward margin	KL	下游准确率
0.05	0.0298	0.0179	0.9049
0.1	0.1165	0.0513	0.9439
0.3	0.8416	0.1310	0.9886
0.5	1.6746	0.1455	0.9934

固定策略时 margin/beta 的变异系数为 0.0000， 是恒等式。真实训练后 beta 改变梯度尺度与收敛位置，变异系数变为 0.5727，四个 beta 的 KL 跨度 0.1276，下游准确率跨度 0.0884。 所以 beta 的调法应该是看 KL 与下游，而不是看 margin。

4　权重层 CPU pilot（真实 Qwen3-0.6B 权重）

4.1　为什么是三层验证

算法实验台验证的是目标函数，权重层 pilot 验证的是代码链路， 完整协议才用于能力结论，三者不能互相替代。本机没有 GPU，但有 CPU 版 torch 与完整的 Qwen3-0.6B 权重，因此可以在缩减规模下把 LoRA-SFT、显式冻结 SFT 参考模型的 DPO、assistant-only masked NLL、 严格三态验证器的生成评测和序列级 KL 的采样估计真实执行一遍。 pilot 用 `configs/model_pilot.yaml` 里写明的规模， 逐条记录写在 `reports/model_pilot_manifest.json`。

表 7　pilot 规模（与正式协议的差别一目了然）

项	pilot	正式协议	说明
LoRA 秩	4	8	pilot 减小可训练参数量
SFT 步数	20	全量 2 epoch	pilot 只验证梯度链路
每组 DPO 步数 / 偏好对	10 / 6	全量 1 epoch	三组对照结构保持一致
评测题数	1 × 5 个子集	303	pilot 每个泛化子集各取一题
生成 token 上限	96	256	pilot 的不可核验率单独报告，不当成答错

4.2　结果

表 8　pilot 上的 masked NLL、生成准确率与不可核验率（1 × 5 题）

策略	masked test NLL	生成准确率	unverifiable 率
Base	2.5602	0.4000	0.6000
SFT	1.2551	0.6000	0.2000
DPO / shortcut	1.2602	0.6000	0.2000
DPO / deconfounded	1.2635	0.6000	0.2000
DPO / length_reversed	1.2583	0.6000	0.2000

表 9　三组 DPO 的隐式 reward margin 与损失

组	margin 前	margin 后	增益	DPO loss 前	DPO loss 后
shortcut	0.0000	0.3617	0.3617	0.6931	0.5305
deconfounded	0.0000	0.1260	0.1260	0.6931	0.6324
length_reversed	0.0000	0.5432	0.5432	0.6931	0.4580

参考模型在训练前用独立基座实例加载同一个 SFT adapter， 逐参数断言与 policy 初值一致（检查了 422 个共享参数）， 再把冻结 ref 的成对 log-ratio 预计算缓存。序列级 KL 用从策略采样的 $\log \pi_\theta - \log \pi_{ref}$ 均值估计为 -0.0129，bootstrap 区间 [-0.0497, 0.0238]， 样本量 4，只作量级参考。

三组在 5 道题上的生成准确率完全相同，这不构成任何能力结论： 缩减后准确率的最小粒度是 0.2，10 步更新也不足以改变 greedy 解码的判对结果。 有区分度的是训练量本身：三组 reward margin 分别从 0.0000 升到 0.3617、 0.1260 与 0.5432， DPO 损失相应下降，说明成对目标函数在真实 Qwen3 权重上确实被优化到了。

序列级 KL 的 MC 估计为 -0.0129，bootstrap 区间跨 0。 KL 本身非负，负值来自只有 4 条采样序列的蒙特卡洛噪声， 不能读作「策略比参考模型更接近」。pilot 的 KL 只用来判断量级， 真要报告 KL 需要更多采样，这正是完整协议里按 prompt 聚类给区间的理由。

pilot 只回答「链路能不能在真实权重上跑通」。 缩减后的样本量与生成长度不足以支持任何关于模型能力的结论， 正式协议的 9 个指标仍为 **pending**， 本节的任何一个数字都不写进简历的能力陈述。

5　三个测量问题

5.1　偏好信号的可识别性

设 S 为一对回答的表面特征差，Q 为真实质量差，Y 为偏好标签。 若存在可测函数 f 使 $Y = f(S)$ 几乎处处，且 $Q \perp Y \mid S$，则 DPO 的经验风险不识别 θ 在 Q 方向的分量。证明的要点是构造观测等价的策略扰动： 对数据集中出现的每个回答给对数概率加同一个常数 c_i， 把腾出的概率质量重新分配给数据集外的回答，成对差 Δ 与损失 L 逐点不变， 而数据集外的行为可以任意改变。等价地，把 θ 分解为控制数据集内相对概率的 φ 与控制数据集外行为的 ψ，似然只依赖 φ，关于 ψ 的 Fisher 信息为零。

把条件做成可操作的量：只用 6 个表面特征训练逻辑回归， 按偏好对分组做 5 折交叉验证，报告 AUC 与 $SI = 2 \cdot AUC - 1$。

表 10　表面特征对偏好标签的可分性

数据	AUC	SI	真错误率	解读
shortcut	1.0000	1.0000	0.0000	标签被表面特征确定性解释
deconfounded	0.5000	0.0000	1.0000	表面线索被切断，只剩质量
length_reversed	1.0000	1.0000	1.0000	线索方向反转，仍可分
旧项目 240 条	1.0000	—	—	reward accuracy 1.0 与数学能力无关

数值上再给两个佐证。把真实质量 Q 在偏好对之间随机重排 50 次， DPO 损失的最大变化是 0.0000，逐位不变。 让 Δ_θ 同时依赖 Q 时，最大变化是 0.0016，非零。这说明损失对 Q 的依赖不是数值噪声， 而是构造上被切断了。

5.2　伪重复与配对推断

40 条测试集来自 2 道题，簇内结果几乎完全一致。用单因素方差分析估簇内相关， 得 ICC 0.7368，设计效应 $deff = 1 + (m - 1)\rho = 15$， 有效样本量 $n_{eff} = n / deff = 2.6667$。 把 40 条当独立样本得到的正态区间是 [0.0212, 0.2288]，不跨 0； 以题目为聚类单位做 bootstrap 得到 [0.0000, 0.2500]，跨 0。 结论从「显著提升」变成「不能拒绝无提升」。

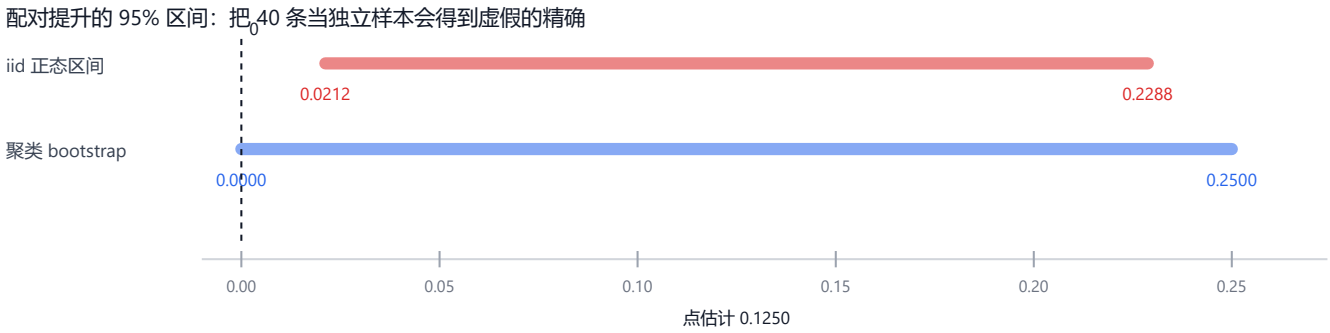


图 4　同一个点估计在两种推断单位下的 95% 区间。聚类区间宽且下界压在 0 上， 这不是估计不精确，而是 2 个簇能提供的信息就这么多。

配对检验给出一致的结论。SFT 对 Base 的 McNemar 精确 p 为 0.0625，三个两两比较做 Holm 校正后最小 p 为 0.1875。按观测到的簇间方差反解功效， 要检出 5 个百分点的提升需要约 99 个独立簇。 现有 2 个簇对应的功效只有 0.0685。

新数据集按题型族做聚类，测试集有 303 条、 12 个族，按同一公式估得的有效样本量在 36.6 到 303.0 之间，取决于簇内相关取中等值还是取 0。这比 40 条对应 2.6667 高两个量级， 但仍然远小于条数本身。

5.3　验证器偏差校正

设真实准确率为 π，验证器的假阳性率为 FPR、假阴性率为 FNR， 观测准确率 $\hat{p} = (1 - \mathrm{FNR})\pi + \mathrm{FPR}(1 - \pi)$，反解得 $\hat{\pi} = (\hat{p} - \mathrm{FPR}) / (1 - \mathrm{FPR} - \mathrm{FNR})$。 用真值已知的 calibration 集估 FPR 与 FNR，再用 survey 集的观测准确率反解， bootstrap 给区间。

表 11　三种验证器在同一批真值已知样本上的表现

验证器	FPR	FNR	观测准确率	校正准确率	未校正偏差	校正后偏差
旧式子串匹配	0.5000	0.1267	0.7425	0.6496	0.0800	-0.0129
严格多项式	0.0000	0.0000	0.6625	0.6625	0.0000	0.0000
数值代入	0.0050	0.0267	0.6475	0.6635	-0.0150	0.0010

构造真值 π = 0.6625。旧式验证器把推导里出现的数字当答案， FPR 高达 0.5000，观测准确率高估 0.0800；校正把偏差压到 -0.0129，代价是分母 1 − FPR − FNR 只有 0.3733，区间明显变宽。

没有人工金标准时，可以用多个验证器的判定做潜类别估计。J 个验证器有 $2^J - 1$ 个自由模式频率，模型有 1 + 2J 个参数，J = 2 时 3 对 5 欠识别，J = 3 时 7 对 7 恰好识别。 三验证器 EM 给出的 $\hat{\pi}$ 是 0.8682，与真值相差 0.0241。代价是覆盖率只有 0.7425，因为只能使用三者都给出二元判定的样本， 被丢掉的几乎都是没有答案标记的错误输出，属于 MNAR。子集真值比全集高 0.2298，这个选择偏差本身就是结论： 直接丢掉不可核验样本再报准确率，会系统性高估。

条件独立是这套估计的硬假设。以 0、0.2、0.5 的概率把第三个验证器的判定替换成第一个， $\hat{\pi}$ 从 0.8682 变到 0.8753，幅度 0.0072。在这批数据上结论不敏感， 但这不构成一般性保证。

6 讨论

三处失效不是并列的，它们互相放大。偏好数据里没有真错误，使梯度只能沿表面特征走； 评测器用子串匹配，使「更长、含更多数字」的回答更容易被判对，于是表面特征与观测收益 同向；测试集是伪重复，使这点收益在统计上显得显著。三者叠加，就得到一条 「loss 下降、margin 上升、准确率不动」的曲线。把其中任何一处单独修掉， 另外两处仍会让结论看起来成立，这也是旧项目反复调参却没有进展的原因。

对工业评测，这套诊断可以直接落成三条操作。上线前给偏好数据做体检， 表面特征基线 AUC 接近 1 就说明这批数据只能教格式。评测集做样本量规划， 用簇内相关算有效样本量，别把同题改写当独立样本，否则 A/B 结论的假阳性会失控。 自动评测器定期用一小批人工标注估 FPR/FNR，把观测准确率还原成真实准确率再报。 三件事都不需要额外训练成本。

局限同样明确。实验台的策略是 7 维解析模型，能验证目标函数却不能替代权重训练， 它的探针设计也参与了结论的构造。权重层 CPU pilot 已在真实 Qwen3-0.6B 权重上跑通缩减协议，但完整协议的 9 个指标 仍为 **pending**。聚类推断只有 2 个簇，簇间方差不可靠， 功效数字只能当量级看。潜类别估计依赖条件独立，敏感性分析只覆盖了一种相关结构。 这些都在结果文件里逐条标注，没有藏在正文之外。

7 复现

研究阶段与算法实验台只用 Python 标准库，不需要 GPU，也不需要安装依赖。 在项目根目录执行：

```
python -m src.run_all --stage research      # 数据、算法实验台、三个测量问题、报告
python -m src.run_all --stage algo          # 单独跑解析策略的 SFT → DPO
python -m src.model.pilot                   # 真实 Qwen3-0.6B 权重上的 CPU pilot
python -m src.run_all --stage check         # 三轮检查
```

产物包括 `data/` 下 600 道题与三组偏好数据、 `reports/results.jsonl` 单一事实源、`reports/research_report.md` 指标表、 `reports/algo_lab_curves.json` 与 `algo_lab_curve.svg` 训练曲线，、`reports/model_pilot_manifest.json` 与逐条预测文件，以及本报告。`reports/check_report.json` 记录三轮检查： 全量编译与单元测试、报告数字逐条反查、原项目 134 个文件哈希未变。 重跑研究阶段后上述文件的哈希逐字节一致。

权重层分两步。CPU pilot 在有 torch 的解释器上执行 `python -m src.model.pilot`，或右键 `run_model_pycharm.py`， 规模写在 `configs/model_pilot.yaml`。完整协议需要 GPU： 安装 `requirements.txt`、准备 Qwen3-0.6B 权重、改三份配置路径后执行 `python -m src.run_all --stage model`，届时 9 个 pending 记录会被同名 measured 替换。依赖缺失时脚本明确报错退出，不会写入任何伪造指标。

本报告由 `src/core/tech_report.py` 从 `reports/results.jsonl` 与 `reports/algo_lab_curves.json` 生成。所有 measured 数字均为真实执行结果； CPU pilot 数字来自真实权重执行，完整协议的 9 个指标仍为 pending。